

THÔNG TIN CHUNG CỦA NHÓM

- Link YouTube video của báo cáo:

<https://youtu.be/69qIgYxJQOA>

- Link slides:

<https://github.com/thanh-nguyendinh/CS2205.CH203/blob/main/PHAN%20TIC%20H%20KHA%20NANG%20LAY%20TRUYEN%20CHI%20THI%20DOC%20HAI%20TRONG%20HE%20THONG%20DA%20TAC%20TU%20DUA%20TREN%20NGON%20NGU%20LON.pdf>

- Sau đó điền vào Đề cương nghiên cứu (tối đa 5 trang), rồi chọn Turn in
- *Lớp Cao học, mỗi nhóm một thành viên*

- Họ và Tên: Nguyễn Đình

Thanh

- MSSV: 250202053



- Lớp: CS2205.CH203

- Tự đánh giá (điểm tổng kết môn): 9.5/10

- Số buổi vắng: 0

- Link Github:

<https://github.com/thanh-nguyendinh/CS2205.CH203>

ĐỀ CƯƠNG NGHIÊN CỨU

TÊN ĐỀ TÀI

PHÂN TÍCH KHẢ NĂNG LÂY TRUYỀN CHỈ THỊ ĐỘC HẠI TRONG HỆ THỐNG ĐA TÁC TỬ DỰA TRÊN NGÔN NGỮ LỚN

TÊN ĐỀ TÀI TIẾNG ANH

ANALYSIS OF MALICIOUS PROMPT PROPAGATION IN LARGE LANGUAGE MODEL-BASED MULTI-AGENT SYSTEMS

TÓM TẮT

Sự dịch chuyển từ Mô hình ngôn ngữ lớn (LLMs) sang Hệ thống đa tác tử (MAS) mang lại cải tiến về tự động hóa, nhưng cũng mở ra các bề mặt tấn công mới. Hiện nay, nghiên cứu bảo mật chủ yếu tập trung vào lỗ hổng tiêm chỉ thị (prompt injection) trên hệ thống đơn lẻ, dẫn đến lầm tưởng rằng các tác tử ẩn sâu trong hệ thống sẽ an toàn do không tiếp xúc trực tiếp với dữ liệu ngoại vi.

Để giải quyết khoảng trống này, luận văn phân tích cơ chế lây nhiễm chỉ thị độc hại (cross-infection LLM-to-LLM), chứng minh một lỗ hổng tiêm chỉ thị vòng ngoài có thể tiến hóa thành "AI virus". Các chỉ thị độc hại này có khả năng tự nhân bản để tiếp cận tác tử ẩn, chiếm đoạt thông tin và thao túng toàn hệ thống.

Về phương pháp, thực nghiệm được tiến hành trên các máy ảo cô lập, sử dụng 2 mô hình ngôn ngữ phổ biến GPT-4o và GPT-3.5 Turbo nhằm chứng minh tính khả thi. Thực nghiệm cũng được thiết lập thành 2 môi trường để đảm bảo tính đa dạng. Tại môi trường tuyến tính, nghiên cứu xây dựng chuỗi ba tác tử trên LangGraph, đo lường Tỷ lệ tấn công thành công (ASR) và đối chiếu lây lan giữa cơ chế truyền tin toàn cục (Global) và cục bộ (Local). Tại môi trường phi tuyến tính, hệ thống LLM Town mô phỏng quần thể 5-15 tác tử giao tiếp ngẫu nhiên. Điểm chính là đánh giá khả năng mã độc thao túng bộ nhớ dài hạn, bắt buộc hệ thống gán điểm "tầm quan trọng" tối đa cho chỉ thị lây nhiễm nhằm duy trì hiện diện bền vững trong nhận thức của tác tử.

Kết quả kỳ vọng sẽ bác bỏ lầm tưởng về sự an toàn của tác tử ẩn, cung cấp minh chứng định lượng về quy luật lây lan theo cấp số nhân của virus chỉ thị trong MAS. Các phát hiện này chỉ ra rủi ro leo thang đặc quyền, thiết lập khung kiểm thử chuyên biệt và tiền đề phát triển cơ chế phòng thủ thế hệ mới như cách ly bộ nhớ và kiểm duyệt thông điệp chéo cho các tác tử.

GIỚI THIỆU

Sự phát triển nhanh chóng của các mô hình ngôn ngữ lớn (LLMs) và xu hướng dịch chuyển sang các hệ thống đa tác tử (Multi-Agent Systems - MAS), cho phép nhiều tác tử phối hợp làm việc thông qua các framework phổ biến như AutoGen [1] hay các hệ thống mô phỏng xã hội [2]. Mặc dù sự liên kết chặt chẽ này mang lại hiệu suất vượt trội, cấu trúc phân tán chứa nhiều tác tử ẩn (shielded agents) hoạt động ở tầng sâu lại vô tình tạo ra những bề mặt tấn công mới, vượt ra ngoài khả năng kiểm soát của các cơ chế bảo mật mô hình đơn lẻ.

Cho đến nay, phần lớn các nghiên cứu về an toàn cho LLMs mới chỉ tập trung vào lỗ hổng của các hệ thống đơn tác tử. Tiêu biểu là kỹ thuật tiêm chỉ thị trực tiếp [3] hoặc gián tiếp qua tài liệu ngoại vi [4], hay sự xuất hiện của các "AI worm" lây lan qua các kênh giao tiếp như email [5]. Khi chuyển quan sát sang môi trường đa tác tử, vấn đề an toàn mới chỉ được khảo sát ở khía cạnh suy giảm hiệu suất do tín hiệu nhiễu [6] hoặc lỗ hổng tiêm chỉ thị gây gián đoạn hành vi cục bộ [7]. Các công trình này vẫn tồn tại hạn chế cốt lõi khi chưa xem xét đầy đủ cơ chế tự nhân bản để lan rộng quy mô tấn công.

Từ những hạn chế trên, khoảng trống nghiên cứu hiện nay xuất phát từ lầm tưởng phổ biến rằng: các tác tử ẩn vốn không tiếp xúc trực tiếp với dữ liệu bên ngoài, sẽ mặc nhiên được an toàn. Sự chủ quan này dẫn đến thiếu hụt nghiêm trọng các khảo sát về cơ chế lây nhiễm có tính hệ thống. Khác biệt với các công trình trước, luận văn này tập trung mô hình hóa cơ chế lây nhiễm chỉ thị độc hại, một dạng tấn công lây nhiễm chéo LLM-to-LLM có khả năng tự nhân bản độc lập. Nghiên cứu hướng tới việc chứng minh cách một lỗ hổng duy nhất từ tác tử vòng ngoài có thể thâm nhập, tự sao chép và truy xuất dữ liệu quan trọng từ các tác tử ẩn, qua đó làm rõ cách thức một rủi ro cục bộ có thể leo thang thành một cuộc tấn công an ninh mang tính toàn hệ thống.

MỤC TIÊU

Để chứng minh thực tế đã nêu, luận văn tập trung trả lời ba câu hỏi cốt lõi.

- Thứ nhất, có thể thiết lập thành công một cuộc tấn công lây nhiễm tự nhân bản thông qua kỹ thuật tiêm chỉ thị nhằm trích xuất thông tin nhạy cảm hay không?
- Thứ hai, phương thức lây truyền này sẽ duy trì hiệu quả lan rộng như thế nào khi triển khai trong môi trường mô phỏng xã hội với tương tác phi tuyến tính?
- Cuối cùng, cơ chế tự nhân bản có tác động định lượng ra sao đối với mức độ rủi ro bảo mật và khả năng thao túng hành vi của các tác tử?

Dựa vào các câu hỏi trên, nghiên cứu xác định ba mục tiêu thực nghiệm cụ thể:

- Mục tiêu đầu tiên là triển khai kỹ thuật lây nhiễm tự nhân bản nhằm trích xuất dữ liệu trên các hệ thống chuỗi tác vụ tuyến tính, tiến hành trên ít nhất hai mô hình ngôn ngữ lớn phổ biến (GPT-4o và GPT-3.5).
- Mục tiêu thứ hai hướng đến việc ứng dụng kỹ thuật lây nhiễm vào môi trường mô phỏng xã hội phi tuyến tính (dựa trên nền tảng LLM Town) với các quy mô quần thể 5 - 15 tác tử, từ đó phân tích tác động trong một mạng lưới đa chiều.
- Mục tiêu cuối cùng là xây dựng phương pháp đánh giá định lượng, tập trung vào Tỷ lệ tấn công thành công (Attack Success Rate) đối với hệ thống tuyến tính và khả năng can thiệp cấu trúc bộ nhớ trong môi trường mô phỏng xã hội.

NỘI DUNG VÀ PHƯƠNG PHÁP

Luận văn đề xuất khung thực nghiệm gồm hai môi trường hoàn toàn độc lập:

- Môi trường tuyến tính: Xây dựng trên LangGraph (dùng GPT-4o và GPT-3.5 Turbo) với chuỗi ba tác tử: Document Reader (tiếp nhận tài liệu), Summarizer (trung gian lọc tài liệu) và Manager (tác tử ẩn truy cập dữ liệu). Hệ thống sẽ đối chiếu hai cơ chế truyền tin cơ bản là Global và Local Messaging.
- Môi trường phi tuyến tính: Kế thừa nền tảng LLM Town để vận hành quần thể (5, 10, 15 tác tử) giao tiếp ngẫu nhiên. Trọng tâm là khai thác hệ thống bộ nhớ dài hạn bằng cách thao túng trực tiếp điểm "tầm quan trọng" của ký ức để đánh giá sự lây lan virus chỉ thị.

Để phục vụ cho các mục tiêu mô phỏng cơ chế tấn công lây nhiễm, nghiên cứu tiến hành xây dựng một bộ dữ liệu thực nghiệm tổng hợp chuyên biệt:

- Đối với môi trường tuyến tính, bộ dữ liệu bao gồm 240 tài liệu độc hại (nhúng 120 chỉ thị đánh cắp dữ liệu giả lập vào email và PDF). Mỗi chỉ thị được cấu trúc 4 phần: Lệnh ghi đè (Prompt Hijacking), Tác vụ độc hại (Payload), Trường lưu trữ (Data) và Cơ chế tự nhân bản (Self-Replication).
- Đối với môi trường mô phỏng xã hội phi tuyến tính, dữ liệu khởi tạo bao gồm 15 các thể tính cách (personas), dữ liệu bộ nhớ gốc và các kịch bản hội thoại nhằm định hình hành vi giao tiếp tự nhiên của quần thể tác tử.

Dựa trên cơ sở đã thiết lập, quy trình thực nghiệm được triển khai tuần tự.

- Môi trường tuyến tính: Cuộc tấn công bắt đầu khi tác tử vòng ngoài tiếp nhận tài liệu độc hại. Nhờ cơ chế tự nhân bản, mã độc tự động lây lan qua tác tử trung gian (Summarizer) và cuối cùng thâm nhập vào tác tử ẩn (Manager) để

thực thi lệnh đánh cắp dữ liệu.

- Môi trường phi tuyến tính: Chỉ thị độc hại được tiêm vào một tác tử khởi nguồn. Qua giao tiếp, mã độc tự sao chép vào câu thoại và bị các tác tử ghi vào bộ nhớ. Việc này giúp mã độc thao túng điểm “tầm quan trọng” mỗi khi bộ nhớ được truy xuất, từ đó lan rộng theo cấp số nhân ra toàn mạng lưới.

Để định lượng mức độ rủi ro, nghiên cứu sử dụng các phương pháp đánh giá sau:

- Đối với môi trường tuyến tính, tiêu chí là Tỷ lệ tấn công thành công (ASR), trong đó một cuộc tấn công chỉ được ghi nhận khi toàn bộ ba tác tử bị thâm nhập và tác tử ẩn thực thi thành công lệnh đẩy dữ liệu ra máy chủ cục bộ. ASR cũng sẽ được đối chiếu đa chiều giữa các kịch bản có và không có lệnh tự nhân bản, giữa hai cơ chế truyền tin cũng như giữa hai thể hệ LLM.
- Đối với môi trường phi tuyến tính, phương pháp đánh giá tập trung vào một khía cạnh khác: khả năng mã độc can thiệp trực tiếp vào mô hình tự đánh giá của LLM để thao túng điểm số "tầm quan trọng" (Importance Score) lên mức tối đa. Từ đó, nghiên cứu định lượng khả năng mã độc bám trụ dài hạn trong nhóm các ký ức ưu tiên của tác tử.

Để tuân thủ theo các nguyên tắc nghiên cứu, toàn bộ quy trình được thực thi thông qua việc kết hợp giao thức gọi API (chỉ dùng cho các tác tử nội bộ hệ thống) và hệ thống máy ảo cô lập. Việc này còn giúp tối ưu hóa tài nguyên vật lý đồng thời triệt tiêu mọi rủi ro an ninh đối với hệ thống bên ngoài.

KẾT QUẢ MONG ĐỢI

Về mặt định lượng, tại môi trường chuỗi tác vụ tuyến tính, luận văn mong đợi thu thập được Tỷ lệ tấn công thành công (ASR) ở mức cao khi áp dụng lệnh tự nhân bản (đạt mức trên 80% đối với các hệ thống chưa được bảo vệ). Các số liệu dự kiến sẽ cho thấy cơ chế Global Messaging rất dễ tổn thương (với ASR dao động từ 55% đến 80%), đồng thời chứng minh việc giới hạn luồng thông tin qua Local Messaging cũng không thể triệt tiêu hoàn toàn sự lan truyền của virus (ASR vẫn có thể kỳ vọng duy trì ở mức ít nhất là 30%). Tại môi trường phi tuyến tính, kết quả được kỳ vọng làm nổi bật quy luật lây lan bùng nổ theo cấp số nhân, tỷ lệ thuận với quy mô quần thể (có thể làm ASR tăng lên mức 80%). Đặc biệt, việc minh chứng khả năng thao túng điểm "tầm quan trọng" của bộ nhớ dài hạn sẽ khẳng định kỹ thuật tiêm chỉ thị có thể định hình lại cấu trúc tư duy của hệ thống.

Dựa trên khung thực nghiệm đã thiết lập, luận văn kỳ vọng cung cấp những minh chứng về khả năng tự lây nhiễm chéo của chỉ thị độc hại trong Hệ thống đa tác tử

(MAS). Về mặt lý luận, kết quả nghiên cứu sẽ bác bỏ lầm tưởng phổ biến về tính an toàn của các tác tử ẩn. Việc làm rõ cơ chế tự nhân bản và chiếm quyền từ bên trong sẽ định hình lại góc nhìn về bề mặt tấn công của hệ thống đa tác tử. Nghiên cứu sẽ chứng minh một lỗ hổng vòng ngoài hoàn toàn có thể tiến hóa thành virus AI, vượt qua các lớp bảo vệ ở tầng sâu mà không cần sự can thiệp từ bên ngoài.

TÀI LIỆU THAM KHẢO

- [1] Qingyun Wu, Gagan Bansal, Jieyu Zhang, Yiran Wu, Beibin Li, Erkang Zhu, Li Jiang, Xiaoyun Zhang, Shaokun Zhang, Jiale Liu, Ahmed Hassan Awadallah, Ryen W. White, Doug Burger, Chi Wang: AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation. CoRR abs/2308.08155 (2023)
- [2] Joon Sung Park, Joseph C. O'Brien, Carrie J. Cai, Meredith Ringel Morris, Percy Liang, Michael S. Bernstein: Generative Agents: Interactive Simulacra of Human Behavior. CoRR abs/2304.03442 (2023)
- [3] Fábio Perez, Ian Ribeiro: Ignore Previous Prompt: Attack Techniques For Language Models. CoRR abs/2211.09527 (2022)
- [4] Kai Greshake, Sahar Abdelnabi, Shailesh Mishra, Christoph Endres, Thorsten Holz, Mario Fritz: Not what you've signed up for: Compromising Real-World LLM-Integrated Applications with Indirect Prompt Injection. CoRR abs/2302.12173 (2023)
- [5] Stav Cohen, Ron Bitton, Ben Nassi: Here Comes The AI Worm: Unleashing Zero-click Worms that Target GenAI-Powered Applications. CoRR abs/2403.02817 (2024)
- [6] Jen-tse Huang, Jiaxu Zhou, Tailin Jin, Xuhui Zhou, Zixi Chen, Wenxuan Wang, Youliang Yuan, Maarten Sap, Michael R. Lyu: On the Resilience of Multi-Agent Systems with Malicious Agents. CoRR abs/2408.00989 (2024)
- [7] Boyang Zhang, Yicong Tan, Yun Shen, Ahmed Salem, Michael Backes, Savvas Zannettou, Yang Zhang: Breaking Agents: Compromising Autonomous LLM Agents Through Malfunction Amplification. CoRR abs/2407.20859 (2024)