

PHÂN TÍCH KHẢ NĂNG LÂY TRUYỀN CHỈ THỊ ĐỘC HẠI TRONG HỆ THỐNG ĐA TÁC TỬ DỰA TRÊN NGÔN NGỮ LỚN

Nguyễn Đình Thanh - 250202053

Tóm tắt

- Lớp: CS2205.CH203
- Link Github của nhóm:
- Link YouTube video:
- Họ và tên học viên: Nguyễn Đình Thanh

Giới thiệu

Bối cảnh & Vấn đề

- **Xu hướng:** Chuyển dịch từ mô hình LLM đơn sang Hệ thống Đa tác tử (MAS).
- **Cấu trúc:** Các "tác tử ẩn", cách ly hoàn toàn với dữ liệu ngoài.
- **Làm tương:** Mặc định "tác tử ẩn" là an toàn vì không tiếp xúc với dữ liệu ngoại vi.

Khoảng trống Nghiên cứu

- Các nghiên cứu hiện tại chỉ tập trung vào bảo mật LLM đơn lẻ hoặc,
- Khảo sát MAS ở khía cạnh suy giảm hiệu suất hoặc gây gián đoạn cục bộ
→ Bỏ ngỏ nguy cơ mã độc **tự nhân bản** trong mạng lưới MAS.

Trọng tâm Luận văn

- Mô hình hóa cơ chế **lây nhiễm chéo** (LLM-to-LLM).
- **Mục tiêu:** Chứng minh mã độc vòng ngoài có thể tự thâm nhập, xuyên thủng hệ thống và chiếm đoạt "tác tử ẩn".



Mục tiêu

- **Chứng minh Khả năng Tấn công trên môi trường tuyến tính:**
 - Triển khai tiên chỉ thị độc hại có kèm phương thức tự nhân bản.
 - Trích xuất dữ liệu thành công từ tác tử ẩn trên chuỗi tác vụ tuyến tính.
- **Khảo sát Khả năng Lây lan trong môi trường mô phỏng xã hội:**
 - Đưa mã độc vào quần thể phi tuyến tính mô phỏng xã hội.
 - Đánh giá mức độ lan truyền qua giao tiếp ngẫu nhiên (5-15 tác tử).
- **Định lượng Mức độ Rủi ro:**
 - **ASR (Tỉ lệ tấn công):** Đánh giá trên môi trường tuyến tính.
 - **Thao túng Bộ nhớ:** Đo lường khả năng can thiệp điểm "tầm quan trọng" trên mô hình phi tuyến tính.

Nội dung và Phương pháp

Thiết lập Môi trường

- **Hệ thống Tuyến tính (LangGraph):**
 - Mô hình: GPT-4o, GPT-3.5 Turbo.
 - Chuỗi 3 tác tử: Reader → Summarizer → Manager (Tác tử ẩn).
 - Đối chiếu: Truyền tin toàn cục (Global) vs. cục bộ (Local).
- **Hệ thống Phi tuyến tính (LLM Town):**
 - Quần thể: 5 - 15 tác tử.
 - Giao tiếp ngẫu nhiên qua mô phỏng xã hội.
 - Trọng tâm: Can thiệp bộ nhớ dài hạn.



Nội dung và Phương pháp


Bộ dữ liệu Thực nghiệm

- **Dữ liệu Tuyến tính:**

- 240 tài liệu mời nhử (gồm Email và PDF), đã được tiêm 120 chỉ thị độc hại.
- Cấu trúc chỉ thị (4 tầng): Lệnh ghi đè → Tác vụ độc hại → Trường trích xuất → Lệnh tự nhân bản.

- **Dữ liệu Phi tuyến tính:**

- 15 Thẻ tính cách (Personas).
- Dữ liệu bộ nhớ gốc.
- Kịch bản hội thoại mời.



Nội dung và Phương pháp

Quy trình Lấy nhiệm

- **Trên Môi trường Tuyển tính:**
 - Tác tử vòng ngoài (Reader) đọc tài liệu mời.
 - Mã độc tự sao chép qua tác tử trung gian (Summarizer).
 - Xâm nhập Tác tử ẩn (Manager) & Đánh cắp dữ liệu.
- **Trên Môi trường Phi tuyển tính:**
 - Tiêm mã độc vào 1 tác tử ban đầu.
 - Lây lan thụ động qua giao tiếp hội thoại.
 - Ghi đè hệ thống bộ nhớ của quần thể.

Phương pháp Đánh giá

- **Chỉ số ASR (Tỉ lệ tấn công):** Đánh giá việc vượt qua cả 3 lớp và đẩy dữ liệu thành công.
- **Mức độ thao túng “điểm quan trọng” (Importance Score),** khả năng buộc hệ thống gán điểm tối đa cho ký ức chứa mã độc.

Kết quả dự kiến

Kết quả Định lượng

- **Đối với môi trường tuyến tính:** Tỷ lệ tấn công (ASR) đạt mức cao (55 - 80%); Local Messaging không chặn được triệt để (kỳ vọng ASR ít nhất 30%).
- **Đối với môi trường phi tuyến tính:** Tốc độ lây lan tăng tỷ lệ thuận với số lượng tác tử và thao túng ít nhất 80% số lượng tác tử, từ đó buộc hệ thống gán điểm "tầm quan trọng" lên mức tối đa.

Kết quả Định tính

- **Sự sụp đổ ranh giới:** Bác bỏ lầm tưởng, chứng minh các "tác tử ẩn" không an toàn tuyệt đối.
- **Hành vi hệ thống:** Xác nhận lỗ hổng vòng ngoài có thể tự tiến hóa thành "vi-rút AI" độc lập.
- **Định hướng phòng thủ:** Đặt tiền đề thiết yếu cho việc xây dựng cơ chế cách ly bộ nhớ và kiểm duyệt chéo.

Tài liệu tham khảo

- [1] Qingyun Wu, Gagan Bansal, Jieyu Zhang, Yiran Wu, Beibin Li, Erkang Zhu, Li Jiang, Xiaoyun Zhang, Shaokun Zhang, Jiale Liu, Ahmed Hassan Awadallah, Ryen W. White, Doug Burger, Chi Wang: AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation. CoRR abs/2308.08155 (2023)
- [2] Joon Sung Park, Joseph C. O'Brien, Carrie J. Cai, Meredith Ringel Morris, Percy Liang, Michael S. Bernstein: Generative Agents: Interactive Simulacra of Human Behavior. CoRR abs/2304.03442 (2023)
- [3] Fábio Perez, Ian Ribeiro: Ignore Previous Prompt: Attack Techniques For Language Models. CoRR abs/2211.09527 (2022)
- [4] Kai Greshake, Sahar Abdelnabi, Shailesh Mishra, Christoph Endres, Thorsten Holz, Mario Fritz: Not what you've signed up for: Compromising Real-World LLM-Integrated Applications with Indirect Prompt Injection. CoRR abs/2302.12173 (2023)
- [5] Stav Cohen, Ron Bitton, Ben Nassi: Here Comes The AI Worm: Unleashing Zero-click Worms that Target GenAI-Powered Applications. CoRR abs/2403.02817 (2024)
- [6] Jen-tse Huang, Jiaxu Zhou, Tailin Jin, Xuhui Zhou, Zixi Chen, Wenxuan Wang, Youliang Yuan, Maarten Sap, Michael R. Lyu: On the Resilience of Multi-Agent Systems with Malicious Agents. CoRR abs/2408.00989 (2024)
- [7] Boyang Zhang, Yicong Tan, Yun Shen, Ahmed Salem, Michael Backes, Savvas Zannettou, Yang Zhang: Breaking Agents: Compromising Autonomous LLM Agents Through Malfunction Amplification. CoRR abs/2407.20859 (2024)